

基于多源异构数据融合的初中数学知识图谱构建

周炫余¹, 唐 祯^{1,2}, 唐丽蓉¹, 李 璇¹, 卢 笑^{3,4†}

1. 湖南师范大学 基础教育大数据研究与应用重点实验室, 湖南 长沙 410006;

2. 厦门大学 教育研究院, 福建 厦门 361005;

3. 湖南师范大学 工程与设计学院, 湖南 长沙 410006;

4. 武汉大学 计算机学院, 湖北 武汉 430072

收稿日期: 2020-11-08 † 通信联系人 E-mail: xlu_hnu@163.com

基金项目: 国家自然科学基金(62007007, 61703155), 湖南省自然科学基金(2018JJ3352, 2018JJ3350), 国家级大学生创新创业训练计划支持项目(S201910542076), 湖南省大学生研究性学习和创新性实验计划项目(S201910542075)

作者简介: 周炫余, 男, 讲师, 现从事中文自然语言处理、教育人工智能等方面的研究。E-mail: zhouxuanyu@whu.edu.cn

摘 要: 知识图谱可以为智能问答和自动推荐等系统提供良好的数据支持。针对国内现有学科知识图谱构建数据来源单一等问题, 提出一种多源异构数据融合的方法构建初中数学知识图谱。基于领域知识和学习者需求构建初中数学本体, 确定概念、方法、公式、定理四种类型的实体; 从教材等权威数据源和百度百科、互动百科等网络数据源中获取非结构化与半结构化数据, 基于 BERT(bidirectional encoder representations from transforms)模型抽取教材等非结构化数据的关系和实体; 利用基于层次过滤思想的知识融合模型进行多源异构数据的融合。实现了基于初中数学知识图谱的智能问答和自动推荐系统, 为学习者提供及时且智能的学习支持服务, 为破解初中数学在线教学个性化不足提供一条思路。

关 键 词: 知识图谱; 多源异构数据融合; 层次过滤模型; 初中数学

中图分类号: TP391.1

文献标志码: A

文章编号: 1671-8836(2021)02-0118-09

Construction of Junior High School Mathematics Knowledge Graph Based on Multi-Source Heterogeneous Data Fusion

ZHOU Xuanyu¹, TANG Zhen^{1,2}, TANG Lirong¹, LI Xuan¹, LU Xiao^{3,4†}

1. Key Laboratory of Big Data Research and Application for Basic Education, Hunan Normal University, Changsha 410006, Hunan, China;

2. Institute of Education, Xiamen University, Xiamen 361005, Fujian, China;

3. College of Engineering and Design, Hunan Normal University, Changsha 410006, Hunan, China;

4. School of Computer Science, Wuhan University, Wuhan 430072, Hubei, China

Abstract: Knowledge graph can provide good data supporting for the intelligent question-answering system and automatic recommendation system. This paper proposes a method of multi-source heterogeneous data fusion to construct junior high school mathematics knowledge graph to solve the problem of a single data source of the existing subject knowledge graph in China. First, the junior high school mathematics ontology was constructed to determine four types of entities: concept, method, formula and theorem based on the domain knowledge and learners' needs. Then, unstructured and semi-structured data were obtained from authoritative data sources such as textbooks and network data sources such as Baidu Wikipedia, HDWiki, and the relationships and entities of unstructured data were extracted from the BERT(bidirectional encoder representations from transforms) model. Then the knowledge fusion model based on multi-pass sieve was used to fuse heterogeneous data from multiple sources. Finally, the intelligent question-answering and automatic recommendation system based on the knowledge graph of junior high school mathematics

引用格式: 周炫余, 唐祯, 唐丽蓉, 等. 基于多源异构数据融合的初中数学知识图谱构建[J]. 武汉大学学报(理学版), 2021, 67(2): 118-126. DOI:10.14188/j.1671-8836.2020.0273.

ZHOU Xuanyu, TANG Zhen, TANG Lirong, et al. Construction of Junior High School Mathematics Knowledge Graph Based on Multi-Source Heterogeneous Data Fusion [J]. J. Wuhan Univ. (Nat. Sci. Ed.), 2021, 67(2): 118-126. DOI:10.14188/j.1671-8836.2020.0273(Ch).

is realized. This study can provide learners with timely and intelligent learning support services, so as to provide an idea for solving the insufficiency of personalization in the online teaching of junior high school mathematics.

Key words: knowledge graph; multi-source heterogeneous data fusion; multi-pass sieve model; junior high school mathematics

0 引言

新型冠状病毒感染肺炎疫情的出现使得教学过程不得不面对教与学分离的情况,为了解决教学分离期间学习者的居家学习问题,教育部发出了“停课不停学”的倡导(http://www.moe.gov.cn/srcsite/A08/s7056/202002/t20200205_418138.html),鼓励各学校充分利用人工智能、网络资源等各种举措来保证在线学习与线下课堂教学质量的实质等效。初中阶段是数学思维形成的关键时期^[1],师生在课堂上的有效交互可以引导学生逐步树立正确的数学思维模式。目前在线教学在时空分离的情况下,大部分教师无法通过面对面观察学生来了解其知识掌握情况,难以同时兼顾所有学习者的需求,造成了学生不懂的知识点不断积累,影响了教学质量。

知识图谱作为人工智能在知识组织和表示方面发展的最新技术,不仅能在不同知识点之间建立语义联系,还能为智能问答和自动推荐等功能提供良好的数据支持。因此,知识图谱不仅能从知识点的语义联系层面来指导学习者的学习,还能应用于个性化学习系统中,解决在线教学中教师答疑反馈不及时和不够个性化的问题。教育领域的知识图谱构建方法主要包括人工构建和自动构建。基于人工构建的方法利用学科教学大纲^[2]、教材、教辅等非结构化文本数据在领域专家的指导下通过构建本体、数据采集、实体抽取、关系抽取、同源数据融合等过程完成知识图谱的构建^[1,3,4]。这样的方法虽能保证教育领域知识图谱的专业性,但耗时费力,不同专家对于同一个知识点的认识会存在偏差,对于基础数学来说,严谨性与一致性难以得到保证^[5]。随着互联网的快速发展,网络上存在着大量半结构化数据,有研究者提出了自动构建的方法,从网络上抽取半结构化文本中的实体、实体关系、实体属性自动构建学科知识图谱^[6~10]。该类方法虽然可以节省大量构建成本,迅速搭建一个知识图谱,但数据的准确性无法得到保障,这对于逻辑严谨的数学学科来说,不是一个合适的选择。

目前学科知识图谱大多基于单一数据来源,无法同时保证构建的效率和准确度,也不能充分覆盖学习者需求。因此,本文提出一种多源异构融合方法构建初中数学知识图谱。该方法用初中数学领

域中的教材知识定义本体并基于BERT(bidirectional encoder representations from transforms)模型^[11]对教材这类非结构数据中的关系和实体进行半自动化的抽取;基于层次过滤的思想,以教材知识为主体,融合百度百科、互动百科等半结构化网络数据源构建初中数学知识图谱。

1 初中数学知识图谱的构建

1.1 总体框架

基于多源异构数据融合的初中数学知识图谱模型包括本体设计、数据获取、知识抽取、知识融合和知识更新5个部分。总体框架如图1所示。

1.2 本体设计

本体是针对概念建模而确立的规则,是对现实世界的抽象描述,通过使用形式化的方式来对概念和概念之间的关系给出明确定义^[11]。它位于知识图谱的模式层,用来概述概念层面的体系,相当于知识库的模具。基于本体定义的知识库不仅具有良好的结构,且重复部分少。尤其在构建学科知识图谱时,事先定义好本体库,就能使知识图谱具有较强的泛化能力。

为了保证初中数学知识图谱的结构合理,本体设计应从以下两个层面考虑:一是初中数学学科的知识体系结构,二是学习者对初中数学知识点提问的需求。教材中的知识点是按照渐进分化和融会贯通原则组织的,因此知识点之间存在上下位的包含关系以及同位关系,能形成一个交错复杂的知识网络。同时具体每个知识点与其他知识点的关系包含了知识点应用的逻辑,因此从这个层面来说,本体的设计应满足学习者掌握知识点应用的需求。

本文构建的知识图谱主要用于支持教学系统的智能问答和自动推荐功能,即除了为学习者解决包括定义以及知识点用法在内的数学问题,还能能为学习者推荐相关知识点进行补充学习。知识点是数学学习中最小级别的知识单元,因此首先依据初中数学领域内重要术语的特性将描述知识点的实体分为概念、公式、方法、定理四类(见表1);其次基于对智能问答功能的考虑,设计各类实体在应用层面的关系。

初中数学实体之间的映射关系定义如下。




图1 基于多源异构数据融合的初中数学知识图谱模型框架图

Fig. 1 The architecture of the junior high school mathematics knowledge graph model based on the fusion of multi-source heterogeneous data

表1 实体类型表

Table 1 Table of entity type

实体类型	中文含义	举例
concept	概念	等腰三角形、代数式
method	方法	合并同类项法则、十字相乘法
formula	公式	平方差公式、完全平方公式
theorem	定理	勾股定理、角平分线定理

定义1 不同初中数学实体之间的映射关系 $R(E_i, E_j)$, 其中 E_i, E_j 为初中数学知识点实体, R 为映射关系, 映射关系包括4类:

1) superior superior 表示的是上位关系。针对实体类型的不同, superior 关系分为 superior_concept 和 superior_method。

2) equative equative 指的是同位关系, 即在知识结构上位于同一层次知识点之间的关系, 比如“直角三角形”和“钝角三角形”就属于同一层次的知识点。针对实体类型的不同, equative 关系分为 equative_concept、equative_theorem、equative_formula 和 equative_method。

3) use use 为运用关系, 是知识点实体需要借助公式、定理或方法来解决的一种关系。比如“直角三角形可以通过使用勾股定理来求得三角形的边”,

“直角三角形”和“勾股定理”就存在着定理 use 关系。针对实体类型的不同, use 关系分为 concept_use_theorem、concept_use_method、concept_use_formula、theorem_use_formula 和 method_use_formula。

4) get get 为得到关系, 指的是知识点实体通过使用公式、定理或方法求得新概念的一种关系。比如直角三角形可以通过使用勾股定理来求得三角形的边, “勾股定理”和“边”就存在着 get 关系。针对实体类型的不同, get 关系分为 theorem_get_concept、method_get_concept 和 formula_get_concept。

以上关系中, 同位关系和上位关系是针对自动推荐功能设计的, 运用和得到关系是基于学习者对知识点如何应用设计的, 各种关系类型及其含义如表2所示。

本文的主要任务是对教材等非结构化数据依照设计的本体结构构建知识图谱, 再将半结构化数据与非结构化数据进行融合, 以构建出多源异构融合的初中数学知识图谱。因此, 通过运用关系和得到关系可以得到一个知识点的应用逻辑, 而这恰好也是智能问答功能的设计逻辑。

1.3 数据获取

数据来源主要包括两部分, 一部分是数学教材、辅导书等非结构化数据, 另一部分是百度百科和互动

表2 关系类型表
Table 2 Table of relation type

实体关系类型	中文含义	举例
superior_concept	概念间的上位关系	〈正方形, superior_concept, 四边形〉
superior_method	方法间的上位关系	〈十字相乘法, superior_method, 因式分解〉
equative_concept	概念间的同位关系	〈三角形, equative_concept, 四边形〉
equative_theorem	定理间的同位关系	〈正弦定理, equative_theorem, 正切定理〉
equative_formula	公式间的同位关系	〈完全平方公式, equative_formula, 平方差公式〉
equative_method	方法间的同位关系	〈交换律, equative_method, 结合律〉
concept_use_theorem	概念运用了定理	〈直角三角形, concept_use_theorem, 勾股定理〉
theorem_get_concept	运用定理得到概念	〈勾股定理, theorem_get_concept, 边〉
concept_use_method	概念运用了方法	〈二元二次方程, concept_use_method, 代入法〉
method_get_concept	运用方法得到概念	〈代入法, method_get_concept, 一元二次方程〉
concept_use_formula	概念运用了公式	〈多项式, concept_use_formula, 平方差公式〉
formula_get_concept	运用公式得到概念	〈求根公式, formula_get_concept, 实数根〉
theorem_use_formula	定理运用了公式	〈勾股定理, theorem_use_formula, 单位圆方程〉
method_use_formula	方法运用了公式	〈配方法, method_use_formula, 平方差公式〉

百科等半结构化数据。数据处理主要包括以下几个方面的工作:1) 定义实体、关系和属性类别:依据问答部分支持的提问类型,在领域专家的指导下完成对实体、关系以及实体类别的定义,确保实体类别的完整性,关系类别的实用性以及属性类别的全面性;2) 数据清洗:对获取的数据进行筛选,将文本数据中重复以及无关的数据删除;3) 分词和词性标注:由于领域内词汇的专业性非常强,直接用分词工具进行分词会导致未登录词过多,结果不理想,因此先利用结巴分词对非结构化数据进行初步的分词和词性标注处理,再人工对分词和标注结果进行校正;4) 标注训练数据:基于领域专家对初中数学学科的整体把握,实现非结构化数据中实体和关系的标注,从而为知识抽取提供数据支持。

1.4 知识抽取

基于网络爬虫获取的多源异构数据,本部分以初中数学知识图谱的本体设计为参照,利用深度学习算法实现初中数学实体及关系的抽取。

1.4.1 关系抽取

基于BERT模型^[12]对实体和关系进行半自动化的抽取。首先针对实体和关系类型定义字典,并以此训练关系分类模型。分类的类别就是基于本体定义的关系种类。因为一句话可能包含多个关系,所以关系分类模型也被视作多标签分类问题。针对具体任务,模型下游采用微调策略,添加池化层和全连接层,并通过Sigmoid激活函数抽取大于一定阈值的关系。目的是以句子级别进行预测,从而得到一句话中包含的多个关系。Sigmoid层关系

预测的概率计算如下

$$P(i) = \frac{e^i}{1 + e^i} \quad (1)$$

根据本体设计部分对关系类型的定义,假设所有关系的类别为 $R = \{r_1, r_2, \dots, r_i\}$, i 表示当前句子经过BERT内若干层神经网络计算后在第 i 个关系类别的分数,通过(1)式分别得到所有类别的最终分数,最后将分数大于一定阈值的类别 r_i 作为预测结果输出,本文中 $1 \leq i \leq 14$ 。关系抽取工作原理如图2所示。

1.4.2 实体抽取

实体抽取模型是基于关系预测结果训练的。当一句话包含多个关系时,使用分类模型输入一个句子只能预测出一个三元组。为了抽取句子中包含的所有实体,将关系整合进实体抽取模型,针对一句话可能出现的 t 个关系,对待预测的句子重复 t 次。当前句子被视作实体抽取模型的Text_a,当前关系被视作Text_b。此时实体抽取模型视作分类问题,根据Text_a中包含的关系,预测每一个tokens的类别。比如标签“B-SUB”表示第一个实体的开头,“I-SUB”表示第一个实体的后续字符。进而根据tokens类别抽取实体对,得到当前句子中包含的实体。实体预测结果计算如下

$$s_i = \arg \max \frac{e^{x_i}}{\sum_{j=1}^4 e^{x_j}} \quad (2)$$

根据本体设计部分对实体类型的定义,假设所有实体的类别为 $S = \{s_1, s_2, s_3, s_4\}$, s_i 表示4种实体类别中针对当前tokens输出的概率最大的实体类别。




图2 关系抽取工作原理图

Fig. 2 Working principle diagram of relation extraction

(2)式中 x_i 表示当前tokens经过BERT内若干层神经网络计算后在第 i 个实体类别的分数,分母是所

有实体类别分数指数的和,此时起归一化作用。其中实体抽取工作原理如图3所示。




图3 实体抽取工作原理图

Fig. 3 Working principle diagram of entity extraction

1.5 知识融合

本文通过网络爬虫技术获取了百度百科和互动百科(在不引起歧义的情况下简称百科)的半结构化数据,百度百科和互动百科的同一实体在名称、属性的表述上不一定相同,教材等非结构化数据与百度百科和互动百科等半结构化数据之间未建立联系,导致数据来源零散,不够权威,不成体系。基于此,在综合考虑了百科已有的各项标签及教材等非结构化文本的情况下,提出一种基于层次过滤思想^[13]的知识融合模型。该模型首先按照实体对齐精度高低设定一系列过滤模块,分别实现百科和文本内部的实体对齐;再以教材知识为主体,

对两类数据进行实体链接,建立起半结构化数据和非结构化数据之间的联系,实现多源异构数据的融合,融合处理逻辑如图4所示,其中以百科实体对齐为例进行介绍,教材文本对齐的逻辑类似。

1.5.1 实体对齐

1) 预处理层:爬虫获取的百科数据一般包含大量重复冗余信息,无法直接用于实体对齐,且后续的工作有赖于各个实体的描述信息,因此本层主要对数据做预处理。对百科数据来说,具体包括:利用百科内的重定向机制和同义词标签去除无关实体,扩充同义实体,得到完整的百科实体集合;再对实体集合中的描述信息进行分词、词性标注、过滤




图4 基于层次过滤思想的知识融合模型处理逻辑示意图

Fig. 4 Processing logic schematic diagram of knowledge fusion model based on hierarchical filtering idea

停用词等文本预处理操作;最后针对已处理完的百科内实体进行百科间的实体对齐(对文本数据,预处理为:分词、词性标注、过滤停用词等常规的文本预处理操作)。

2) 字符串匹配层:主要用于匹配百科间名称和描述信息完全一致的实体,例如百度百科中的“一元一次方程”和互动百科中的“一元一次方程”是完全匹配的两实体,此时只保留其中一个。

3) 语义匹配层:实体对齐工作一般可以转化为对实体语义相似度的判断^[14]。大多数情况下会利用中文语义知识库(HowNet)来计算实体对之间的语义相似度,基于HowNet语义相似度计算考虑的是两实体在知网中的义元相似度,计算公式如下

$$\text{Sim}_h(\text{HA}_i, \text{BA}_j) = \frac{\alpha}{s + \alpha} \quad (3)$$

其中, HA_i 和 BA_j 分别表示互动百科和百度百科中某实体的名称, s 为实体 HA_i 和 BA_j 的义元在义元层次体系中的距离, α 是一个可调节的参数,当 $\text{Sim}_h(\text{HA}_i, \text{BA}_j)$ 大于 0.5 的时候,两实体具有语义相似性。

然而 HowNet 规模较小,不能完全计算出所有实体对的语义相似度。因此,本层在本地语义知识库的基础上,还引入 Web 语义知识来计算语义相似度。基于 Web 语义相似度的计算主要利用搜索引擎索引出的网页信息,并以此计算两实体的语义相似度,计算公式如下

$$\text{NGD}(\text{HA}_i, \text{BA}_j) = \frac{\max \{ \log f(\text{HA}_i), \log f(\text{BA}_j) \} - \log f(\text{HA}_i, \text{BA}_j)}{\log M - \min \{ \log f(\text{HA}_i), \log f(\text{BA}_j) \}} \quad (4)$$

其中, M 指的是谷歌搜索的网页总数, $f(\text{HA}_i)$ 指的是实体名 HA_i 作为搜索词在网页中的命中数量,

$f(\text{HA}_i, \text{BA}_j)$ 则是指同时出现两词的网页数量。

4) 词形匹配层:词形匹配层主要是在语义相关的基础上,计算属性标签和摘要文本的相似度。属性标签指的是百度百科和互动百科上对某一个实体信息的描述内容,摘要文本指的是百度百科和互动百科上对某个概念用相对精炼文字介绍的内容。属性标签的相似度用编辑距离算法计算。考虑到属性匹配个数对相似度的影响^[15],本文对公式做了归一化处理,计算如下

$$\text{Sim}_a(h^{\text{HA}_p}, b^{\text{BA}_q}) = \frac{\sum_{h_m \in \text{HA}_p, b_n \in \text{BA}_q} \text{sim}_{\text{edit}}(\bar{h}_m^{\text{HA}_p}, \bar{b}_n^{\text{BA}_q})}{l} \quad (5)$$

其中, $h^{\text{HA}_p} = \{h_1^{\text{HA}_p}, h_2^{\text{HA}_p}, \dots, h_m^{\text{HA}_p}, \dots\}$ 和 $b^{\text{BA}_q} = \{b_1^{\text{BA}_q}, b_2^{\text{BA}_q}, \dots, b_n^{\text{BA}_q}, \dots\}$ 分别表示互动百科中第 p 个实体 HA_p 和百度百科中第 q 个实体 BA_q 属性名集, $\bar{h}_m^{\text{HA}_p}, \bar{b}_n^{\text{BA}_q}$ 指的 $h_m^{\text{HA}_p}, b_n^{\text{BA}_q}$ 对应的属性值, $\text{sim}_{\text{edit}}(\bar{h}_m^{\text{HA}_p}, \bar{b}_n^{\text{BA}_q})$ 指的是属性值 $\bar{h}_m^{\text{HA}_p}$ 和 $\bar{b}_n^{\text{BA}_q}$ 之间的编辑距离, l 表示实体 BA_q 的属性个数。

摘要文本相似度的计算使用的是基于 TF-IDF 的余弦相似度算法。首先分别将从互动百科和百度百科提取的关键词转换成长度为 l 的向量 $\text{HS}_1 = \{x_1, x_2, \dots, x_l\}$ 和 $\text{BS}_1 = \{y_1, y_2, \dots, y_l\}$,再计算两向量之间的余弦相似度,如下

$$\text{Sim}_s(\text{HS}_1, \text{BS}_1) = \frac{\sum_{i=1}^l (x_i \times y_i)}{\sqrt{\sum_{i=1}^l (x_i)^2 \times \sum_{i=1}^l (y_i)^2}} \quad (6)$$

5) 实体融合层:融合词形匹配层的属性标签和摘要文本相似度计算的结果,按下式计算两实体间的最终相似度

$$\text{SIM}(\text{he}_p, \text{be}_q) = w_1 \times \text{Sim}_a(h^{\text{HA}_p}, b^{\text{BA}_q}) + w_2 \times \text{Sim}_s(\text{HS}_p, \text{BS}_q) \quad (7)$$

其中, he_p 和 be_q 分别代表互动百科和百度百科内的第 p 和第 q 个实体, w_1 和 w_2 分别代表此次融合中属性标签的相似度和摘要文本的相似度所占权重。若计算结果大于一定阈值, 实体对齐; 否则, 不对齐。

1.5.2 实体链接

实体链接指的是将百科文本中的实体指称项链接到非结构化文本知识库中对应实体对象的操作。一般包括文本实体抽取、候选实体生成、实体指称项链接三部分的工作。文本实体的抽取工作可利用上述提到的知识抽取模型完成; 候选实体生成的过程实际上就是对抽取的实体指称项生成可能链接的候选实体集合, 其中可能会涉及一词多义的情况, 可应用上述提到的实体对齐框架来同步完成; 实体指称项链接指的是从候选实体中选择正确的链接对象, 将实体指称项与知识库中的实体建立联系。通过以上三个步骤就实现了百科实体和教材文本知识库的链接。

考虑到知识库中的实体无属性内容的描述, 因此直接利用本地语义知识库和 Web 语义知识库, 通过计算实体指称项和候选实体之间的语义相似度来判断两实体间的关联性, 再将实体指称项和相似度高的候选实体链接起来, 实现多源异构数据的融合。

1.6 知识更新

知识图谱更新主要分为两个部分, 即知识图谱的局部更新和周期性更新。知识图谱的局部更新是以教材等非结构化数据为基础, 利用网络资源等半结构化数据进行非结构化数据的更新; 知识图谱的周期更新是将网络上实时更新的知识周期性地融合进已有知识图谱。

2 可视化与应用

2.1 知识图谱可视化展示

通过对抽取的知识进行融合, 最终得到了 4 910 个数学实体和 1 941 条关系。考虑到图数据库的存储方式与知识图谱三元组结构一致, 将抽取的知识库以可视化图数据库 Neo4j 进行管理, 部分数据如图 5 所示。

2.2 应用

基于上述方法构建的初中数学知识图谱, 我们开发了初中数学智能问答推荐系统, 主要从智能问答和自动推荐功能出发, 以提供个性化和智能化学习支持服务为导向, 实现对不同学习者数学知识点的辅导, 进而提升在线教学的效果。




图 5 多源异构融合初中数学知识图谱图(部分)

Fig. 5 Multi-source heterogeneous fusion of junior high school mathematics knowledge graph (partly)

2.2.1 及时提供在线教学辅导, 实现初中数学知识智能问答

知识图谱具有结构化和关联化的特征, 能为各类智能问答系统提供问题在语义层面上的理解, 使得计算机理解用户提出的问题成为可能, 免去了用户二次检索或筛选的过程, 大幅度提高了答案返回的准确性和用户的使用体验。而智能问答系统中, 问句的解析效果及答案反馈的准确性取决于知识图谱的数据量大小, 例如搜索“如何求直角三角形的边?”, 只有足够全面的知识图谱才可以充分挖掘出这句话包含的知识点实体, 并通过知识图谱建立联系反馈答案, 如图 6 所示。因此基于多源异构数据融合的初中数学知识图谱实现的智能问答功能, 不仅能照顾到不同学习者对不同知识点的学习需求, 使每个问题得到及时有效地解决, 还减轻了在线教学教师的工作负担, 使其可以将工作重心更多地放在教学设计上, 促进教与学共同发展。

2.2.2 按需推送相关知识点, 实现初中数学知识自动推荐

智慧教育的技术特征之一是按需推送, 即能够根据学习者的偏好和需求推送相应的学习资源和信息, 为学习者提供个性化和适应性服务。虽然目前网络上提供的学习资源非常丰富, 能从多方面满足学习者的学习需求, 但存在着不具针对性, 并未考虑知识点关联性以及学习内容内部结构的问题。而多源异构数据融合的初中数学知识图谱包含了多个知识点, 能挖掘到更多联系, 建立更为复杂的关系, 从而形成一个全面的网状结构图。因此基于多源异构数据融合的知识图谱实现的自动推荐功能, 能够对学习者的提问进行充分分析, 并基于问题及知识图谱中知识点的复杂关联性来推测学习者感兴趣甚至薄弱的知识点, 从而更具个性化及针




图6 智能问答功能示例图

Fig. 6 Example diagram of smart question answering function

对性地为学习者提供学习支持服务。如图7所示, 学习者在搜索与代数式相关的知识点后, 可以得到

相关知识点的推荐, 点击链接, 即可跳转界面了解其详细信息。




图7 自动推荐功能示例图

Fig. 7 Example diagram of automatic recommendation function

3 结 语

本文通过融合多源异构数据, 并利用BERT模型半自动构建初中数学知识图谱。在知识融合部分提出基于层次过滤思想的知识融合模型, 并引入Web语义知识, 将结构化数据和半结构化数据中的实体进行对齐和链接, 将知识图谱应用于智能问答和自动推荐中, 通过知识关联和知识推理深度分析

学习者的需求, 从而更具个性化地为学习者提供学习支持。本文的研究为教育领域知识图谱的构建, 以及知识图谱在教育领域的智能化应用提供了思路。

参考文献:

- [1] 喻平, 董林伟. 初中数学实验的本质解析[J]. 课程·教材·教法, 2016, 36(8): 89-95. DOI: 10.19877/j.cnki.

- kcjcf.2016.08.014.
- YU P, DONG L W. Analysis of nature of mathematics experiment in junior middle school [J]. *Curriculum, Teaching Material and Method*, 2016, **36**(8): 89-95. DOI: 10.19877/j.cnki.kcjcf.2016.08.014(Ch).
- [2] 李艳燕, 张香玲, 李新, 等. 面向智慧教育的学科知识图谱构建与创新应用[J]. *电化教育研究*, 2019, **40**(8): 60-69. DOI:10.13811/j.cnki.eer.2019.08.008.
- LI Y Y, ZHANG X L, LI X, *et al.* Construction and innovative application of discipline knowledge graph oriented to smart education [J]. *E-Education Research*, 2019, **40**(8): 60-69. DOI:10.13811/j.cnki.eer.2019.08.008(Ch).
- [3] 朱游娟. 初中数学问题的全知识图谱设计与实现[D]. 成都: 电子科技大学, 2016. DOI:10.7666/d.D00990642.
- ZHU Y J. *Design and Implementation of Full Knowledge Map for the Math Problems in Junior High School* [D]. Chengdu: University of Electronic Science and Technology of China, 2016. DOI:10.7666/d.D00990642(Ch).
- [4] 徐增林, 盛泳潘, 贺丽荣, 等. 知识图谱技术综述[J]. *电子科技大学学报*, 2016, **45**(4): 589-606. DOI:10.3969/j.issn.1001-0548.2016.04.012.
- XU Z L, SHENG Y P, HE L R, *et al.* Review on knowledge graph techniques [J]. *Journal of University of Electronic Science and Technology of China*, 2016, **45**(4): 589-606. DOI:10.3969/j.issn.1001-0548.2016.04.012(Ch).
- [5] 李振, 周东岱, 王勇. “人工智能+”视域下的教育知识图谱: 内涵、技术框架与应用研究[J]. *远程教育杂志*, 2019, **37**(4): 42-53.
- LI Z, ZHOU D D, WANG Y. Research of educational knowledge graph from the perspective of “artificial Intelligence+”: Connotation, technical framework and application [J]. *Journal of Distance Education*, 2019, **37**(4): 42-53(Ch).
- [6] VILLALON J, CALVO R A. Concept extraction from student essays, towards concept map mining [C]// *Proceedings of the 5th IEEE*. Piscataway: IEEE Press, 2009: 221-225.
- [7] WEN Y, LOOI C K, CHEN W. Appropriation of a representational tool in a second-language classroom [J]. *International Journal of Computer Supported Collaborative Learning*, 2015, **10**(1): 77-108. DOI:10.1007/s11412-015-9208-0.
- [8] LIN Y S, CHANG Y C, LIEW K H. Effects of concept map extraction and a test-based diagnostic environment on learning achievement and learners' perceptions [J]. *British Journal of Educational Technology*, 2016, **47**(4): 649-664. DOI:10.1111/bjet.12250.
- [9] 陆泉, 谢祎玉, 陈静, 等. 临床医学课程知识主题图谱构建研究[J]. *图书情报工作*, 2019, **63**(9): 101-108.
- LU Q, XIE Y Y, CHEN J, *et al.* Research on the construction of clinical medicine course-knowledge topic graph [J]. *Library and Information Service*, 2019, **63**(9): 101-108(Ch).
- [10] 郭琴芳. 基于知识图谱的初中数学在线学习系统及应用[D]. 西安: 西安理工大学, 2019.
- GUO Q F. *Junior High School Online Learning System Based on Knowledge Graph* [D]. Xi'an: Xi'an University of Technology, 2019(Ch).
- [11] 刘峤, 李杨, 段宏, 等. 知识图谱构建技术综述[J]. *计算机研究与发展*, 2016, **53**(3): 582-600. DOI:10.7544/issn1000-1239.2016.20148228.
- LIU Q, LI Y, DUAN H, *et al.* Knowledge graph construction techniques [J]. *Journal of Computer Research and Development*, 2016, **53**(3): 582-600. DOI:10.7544/issn1000-1239.2016.20148228(Ch).
- [12] HUI B, LIU L, CHEN J, *et al.* Few-shot relation classification by context attention-based prototypical networks with BERT [J]. *EURASIP Journal on Wireless Communications and Networking*, 2020, **118**: 1-17. DOI: 10.1186/s13638-020-01720-6.
- [13] 周炫余, 刘娟, 邵鹏, 等. 基于层次过滤模型的中文指代消解[J]. *吉林大学学报(工学版)*, 2016, **46**(4): 1209-1215. DOI:10.13229/j.cnki.jdxbgxb201604029.
- ZHOU X Y, LIU J, SHAO P, *et al.* Chinese Anaphora resolution based on multi-pass sieve model [J]. *Journal of Jilin University (Engineering and Technology Edition)*, 2016, **46**(4): 1209-1215. DOI:10.13229/j.cnki.jdxbgxb201604029(Ch).
- [14] 付洋, 刘茂福, 乔瑞. 心脏病中文知识图谱的构建[J]. *武汉大学学报(理学版)*, 2020, **66**(3): 261-267. DOI:10.14188/j.1671-8836.2018.0217.
- FU Y, LIU M F, QIAO R. Construction of Chinese knowledge graph of heart disease [J]. *Journal of Wuhan University (Natural Science Edition)*, 2020, **66**(3): 261-267. DOI:10.14188/j.1671-8836.2018.0217(Ch).
- [15] 王雪鹏, 刘康, 何世柱, 等. 基于网络语义标签的多源知识库实体对齐算法[J]. *计算机学报*, 2017, **40**(3): 701-711. DOI:10.11897/SP.J.1016.2017.00701.
- WANG X P, LIU K, HE S Z, *et al.* Multi-source knowledge bases entity alignment by leveraging semantic tags [J]. *Chinese Journal of Computers*, 2017, **40**(3): 701-711. DOI:10.11897/SP.J.1016.2017.00701(Ch).
-